

MECANISMO DE HANDOVER PREDITIVO PARA REDES VEICULARES UTILIZANDO 5G

Ester Sara Assis Silva

Departamento de Ciência da Computação, Universidade Federal de Minas Gerais

Belo Horizonte, Brasil

estersilva@dcc.ufmg.br

ABSTRACT

Este artigo propõe um mecanismo de handover preditivo para redes veiculares 5G, utilizando redes LSTM para antecipar trocas de conexão com base em dados de mobilidade e qualidade de sinal. O estudo emprega mapas reais (OpenStreetMap) e simulações no SUMO, com a rede modelada em OMNeT++, INET Framework, Veins e Simu5G. O modelo é treinado offline e avaliado com métricas de aprendizado de máquina (acurácia, F1-score) e de rede (taxa de handover, latência, throughput). Os experimentos buscam investigar a viabilidade de abordagens preditivas na manutenção da continuidade de serviço em cenários de alta mobilidade, com foco em aplicações futuras para redes 6G.

1. INTRODUÇÃO

As redes móveis de quinta e sexta geração (5G e 6G) representam um avanço significativo em termos de velocidade, latência e capacidade de conexão. Esses ganhos são possibilitados por uma maior densidade de antenas com menor alcance individual, o que reduz a latência e melhora a qualidade de serviço (QoS) para dispositivos em movimento. Essa infraestrutura tem impacto direto em aplicações críticas, como carros conectados, transporte inteligente e comunicação veicular, onde a continuidade da conexão é essencial para a segurança e eficiência.

No entanto, a mobilidade em redes veiculares impõe desafios específicos. À medida que veículos se deslocam em alta velocidade por áreas densamente cobertas por estações rádio-base (gNBs), o número de trocas de conexão entre antenas (em termos técnicos, handover) aumenta drasticamente. Se forem mantidas políticas tradicionais de handover baseadas apenas na degradação do sinal, ocorrem consequências negativas como aumento da latência, interrupções momentâneas de serviço e perda de pacotes. Esse comportamento compromete aplicações sensíveis ao tempo, como comunicação veículo-veículo (V2V) e veículo-infraestrutura (V2I).

Neste trabalho, é proposto um mecanismo de handover preditivo baseado em aprendizado de máquina supervisionado, com foco em redes LSTM (Long Short-Term Memory), que utiliza rastros de mobilidade e indicadores de qualidade de sinal para antecipar eventos de handover. O modelo é treinado offline com dados extraídos de simulações realistas, utilizando mapas do OpenStreetMap com-

binados com tráfego gerado no SUMO, e a rede simulada com OMNeT++, Veins, INET Framework e Simu5G. Os resultados obtidos são avaliados com métricas tanto de aprendizado de máquina (acurácia, F1-score, matriz de confusão) quanto de desempenho de rede (taxa de handover, ping-pong, latência, throughput), buscando demonstrar ganhos significativos em relação às abordagens convencionais.

Diferentemente de trabalhos anteriores que focam exclusivamente em heurísticas de rede ou simulações teóricas, a proposta combina mobilidade realista, simulação de redes 5G completas e técnicas modernas de predição baseadas em séries temporais. Essa abordagem híbrida permite investigar o comportamento do sistema em cenários urbanos, rodoviários e mistos, oferecendo uma contribuição prática e reproduzível para a comunidade de redes móveis veiculares.

O restante deste artigo está estruturado da seguinte forma: a próxima seção apresenta o background teórico e técnico necessário para o entendimento do problema e das ferramentas utilizadas. Em seguida, a seção de implementação detalha a configuração dos cenários, coleta e pré-processamento dos dados, e o treinamento do modelo preditivo. A seção de resultados apresenta e discute os principais achados, seguida da revisão dos trabalhos relacionados e da conclusão com sugestões para trabalhos futuros.

2. BACKGROUND

A seção de fundamentação teórica apresenta os conceitos necessários para a compreensão do trabalho desenvolvido. São descritos os principais elementos que compõem o cenário de redes veiculares, as características das redes 5G e 6G, os desafios relacionados ao processo de handover, bem como as abordagens existentes baseadas em aprendizado de máquina. O conteúdo tem como objetivo fornecer ao leitor o contexto técnico necessário para o entendimento das decisões de modelagem e simulação adotadas neste estudo. Conceitos amplamente discutidos na literatura são apresentados de forma resumida, com referência às fontes originais.

2.1 Handovers em Redes Móveis

O handover é o processo que permite a continuidade de uma conexão quando um dispositivo móvel se desloca en-




Figure 1. Diferença entre Hard Handover e Soft Handover

tre diferentes áreas de cobertura celular. Em redes móveis, especialmente nas de quinta geração (5G), esse processo é fundamental para garantir qualidade de serviço (QoS) em cenários com alta mobilidade, como ambientes veiculares.

De forma geral, o handover envolve três fases: descoberta da rede, decisão e execução. A rede precisa identificar o momento apropriado para iniciar a transição e garantir que o dispositivo móvel esteja conectado à célula com melhor desempenho, sem causar interrupções na comunicação. Um dos métodos mais tradicionais é o hard handover (HHO) (Figura 1), também conhecido como break-before-make. Nesse modelo, a conexão com a célula atual é encerrada antes que uma nova seja estabelecida, o que pode causar aumento de latência ou perda de pacotes durante a transição, especialmente crítico para aplicações em tempo real como VoIP.

Embora redes como LTE e 5G tenham introduzido melhorias, como o suporte a handover rápido e mecanismos de soft handover em cenários específicos, o HHO ainda é amplamente utilizado devido à sua simplicidade de implementação. Em ambientes com alta densidade de células e mobilidade intensa, como em redes veiculares, a utilização exclusiva do hard handover pode gerar problemas como ping-pong (trocas excessivas de célula) e degradação da qualidade da conexão, o que reforça a necessidade de técnicas mais inteligentes de previsão e controle do processo [1].

2.2 Simulação de Redes Veiculares

Simular redes veiculares com suporte a 5G exige a combinação de múltiplas ferramentas especializadas, cada uma responsável por representar aspectos específicos do sistema. O ambiente adotado neste trabalho integra os simuladores SUMO, OMNeT++, os frameworks Veins, INET e Simu5G, e arquivos derivados de OpenStreetMap (OSM). Essa integração permite representar mobilidade realista, comunicação em rede, e comportamentos avançados de sistemas móveis com suporte à tecnologia 5G NR.

O SUMO (Simulation of Urban Mobility) é um simulador de tráfego veicular que permite importar mapas reais (como os do OpenStreetMap), definir rotas dinâmi-

cas, controlar semáforos e modelar diferentes comportamentos de condução. O uso do SUMO é essencial para garantir que os padrões de movimentação veicular na simulação reflitam situações urbanas e rodoviárias reais.

O OMNeT++ é uma plataforma de simulação baseada em eventos discretos, extensível e modular, adequada para simulações de redes de computadores e sistemas distribuídos. É usado como núcleo da simulação de rede, permitindo controlar o fluxo de pacotes, o desempenho dos nós de rede e a coleta de métricas detalhadas.

Para conectar a mobilidade do SUMO ao ambiente de rede do OMNeT++, utiliza-se o Veins (Vehicles in Network Simulation), um framework que integra os dois simuladores por meio do protocolo TraCI. Essa interface garante que as posições dos veículos, controladas pelo SUMO, sejam refletidas dinamicamente no OMNeT++ durante a simulação.

O INET Framework fornece os modelos de pilha de protocolos de rede (IP, TCP, UDP, etc.), mobilidade, roteamento e dispositivos físicos para o OMNeT++. Ele é responsável por simular a parte clássica da rede, como o roteamento IP e o tráfego de dados.

O Simu5G é um framework construído sobre o INET que adiciona suporte à simulação de redes 5G, incluindo a pilha de protocolos NR, mecanismos de associação por SINR, módulos de handover, slicing, gerenciamento de tráfego e comunicação D2D. Ele também implementa funcionalidades como múltiplas células (gNodeBs), canais com perda, HARQ e monitoramento de qualidade de enlace. Sua presença na simulação é crucial para modelar os efeitos do handover em uma rede 5G realista, e para testar estratégias de predição baseadas em métricas como CQI e latência.

A combinação dessas ferramentas proporciona um ambiente de simulação flexível, escalável e realista, capaz de representar tanto a mobilidade veicular quanto os aspectos físicos e lógicos da rede 5G, permitindo avaliar com precisão o desempenho de estratégias de handover em cenários diversos.

2.3 Técnicas de ML em Redes Veiculares

O uso de aprendizado de máquina (ML) em redes veiculares tem se mostrado promissor para diversas aplicações, como predição de handover, detecção de anomalias, gerenciamento de recursos, roteamento adaptativo e tomada de decisão colaborativa. Modelos supervisionados, como redes neurais recorrentes (LSTM), random forests e SVMs, têm sido aplicados para prever padrões de mobilidade, qualidade de canal e eventos de rede com base em séries temporais e dados contextuais.

Segundo Qin et al. (2021), uma das grandes vantagens do ML em redes veiculares está na capacidade de aprender relações complexas e dinâmicas entre variáveis heterogêneas, que incluem métricas de sinal, localização, velocidade, interferência e carga da rede. No entanto, a aplicação prática desses modelos enfrenta desafios significativos, principalmente relacionados à coleta e ao tratamento dos dados de entrada.




Figure 2. Visualização do mapa do cenário A no OpenStreetMap e no SUMO




Figure 3. Visualização do mapa do cenário B no OpenStreetMap

<https://www.sciencedirect.com/science/article/pii/S2352864821000070>

3. IMPLEMENTAÇÃO

3.1 Configuração dos Cenários de Mobilidade

O processo de geração da mobilidade veicular foi realizado utilizando o simulador SUMO, a partir de mapas reais obtidos do OpenStreetMap. Esses mapas são convertidos em uma rede viária simulável por meio de ferramentas auxiliares fornecidas pelo próprio SUMO. O pipeline envolve a criação de arquivos intermediários que representam a estrutura da rede, os trajetos, as rotas dos veículos e os parâmetros de execução da simulação. Assim, foram definidos três cenários de mobilidade distintos, representando diferentes perfis de tráfego urbano e rodoviário. A Tabela 1 resume os principais arquivos gerados, suas finalidades e quando são criados no processo.

Arquivo	Finalidade
.osm	Dados geográficos do mapa (vias, interseções, etc.)
.net.xml	Rede viária com cruzamentos, faixas e regras de tráfego
.trips.xml	Lista de viagens contendo apenas origem e destino dos veículos
.rou.xml	Rotas completas dos veículos a partir das trips
.sumo.cfg	Arquivo principal de configuração do SUMO, que conecta todos os outros
.launchd.xml	Define a integração entre SUMO e OMNeT++ via Veins (TraCI)

Table 1. Arquivos utilizados na geração da mobilidade no SUMO

3.1.1 Cenário A

O Cenário A (Figura 2) corresponde à região do bairro Liberdade, nas proximidades da Universidade Federal de Minas Gerais (UFMG), em Belo Horizonte. Essa área apresenta características de bairro estudantil, com vias urbanas locais e tráfego moderado. A mobilidade simulada foi configurada com velocidade média de 50km/h e densidade intermediária (um veículo a cada dois segundos). O perfil representa deslocamentos fluidos com interações ocasionais entre os nós móveis.

3.1.2 Cenário B

O Cenário B (Figura 3) foi construído com base na rodovia BR-381, importante eixo de ligação entre Minas Gerais e São Paulo. Este cenário caracteriza-se por mobilidade elevada e tráfego mais espaçado, simulando condições típicas de tráfego rodoviário. Os veículos alcançam velocidades de até 120km/h, com intervalo médio de geração de um



Figure 4. Visualização do mapa do cenário C no OpenStreetMap

novo veículo a cada seis segundos. O perfil reflete o comportamento de veículos rápidos com maior espaçamento, o que reduz a frequência de eventos de handover e minimiza interferências locais.

3.1.3 Cenário C

O Cenário C (Figura 4) representa um ambiente urbano denso, baseado na Avenida Paulista, em São Paulo: Um dos centros comerciais mais movimentados do país. Esse cenário foi configurado para simular tráfego intenso e deslocamento veicular lento, com velocidade média limitada a aproximadamente 30km/h e densidade elevada (um novo veículo a cada 0.1 segundo). O perfil reproduz a realidade de veículos próximos uns dos outros, em movimento constante porém lento, o que aumenta a demanda por recursos de rede e a incidência de handovers sucessivos.

Esses três perfis complementares foram selecionados para representar situações reais enfrentadas por redes veiculares 5G, permitindo analisar a robustez de mecanismos preditivos de mobilidade sob diferentes pressões de tráfego e variações topológicas.

3.2 Configuração da Rede de Comunicação

A simulação da rede de comunicação foi implementada no ambiente OMNeT++, integrando os frameworks INET, Veins e Simu5G. A configuração do cenário segue uma arquitetura modular que espelha uma rede móvel baseada em 5G NR, com múltiplas estações rádio-base, um roteador central, um servidor, um UPF e veículos conectados dinamicamente às células. A simulação em andamento para cenário A podem ser vistas na Figura 5, para o cenário B, Figura 6, e C, Figura 7.



Figure 5. Simulação em andamento no Omnetpp para o cenário A




Figure 6. Simulação em andamento no Omnetpp para o cenário B

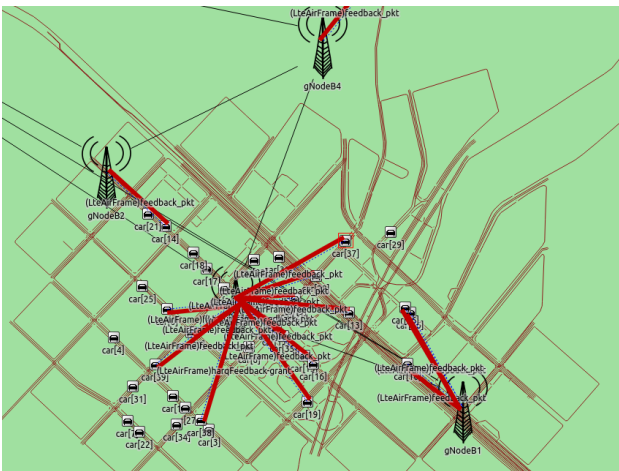


Figure 7. Simulação em andamento no Omnetpp para o cenário C

3.2.1 Arquitetura no OMNeT++

A rede foi modelada por meio do arquivo NED Highway5G.ned, no qual os módulos principais estão definidos de forma hierárquica. A infraestrutura inclui:

- Um módulo central `veinsManager`, responsável pela coordenação da mobilidade via TraCI (SUMO).
- Quatro estações rádio-base (gNodeB1 a gNodeB4) conectadas ao UPF por meio de enlaces Ethernet (modelo `Eth10G`).
- Um roteador e um servidor conectados ao UPF, representando o core da rede.
- Módulos visuais auxiliares, como `IntegratedVisualizer` e `RoadsCanvasVisualizer`, que facilitam o acompanhamento da simulação.

As conexões entre os gNodeBs são realizadas via interface X2, com suporte ao protocolo SCTP, configuradas de forma par-a-par para permitir controle de handover distribuído.

3.2.2 Configuração de Parâmetros Físicos e de Rede

A camada física e a camada de enlace da rede foram configuradas com parâmetros projetados para refletir condições realistas de operação em ambientes veiculares, garantindo equilíbrio entre fidelidade do modelo e estabilidade da simulação. As definições adotadas abrangem potência de transmissão, largura de banda, limiares para handover e latências operacionais.

3.2.3 Configuração das Estações Rádio-Base (gNodeBs)

As estações rádio-base foram posicionadas manualmente no espaço de simulação, com coordenadas específicas para cada cenário (A, B ou C), por meio dos parâmetros `initialX`, `initialY` e `initialZ`. Essa configuração espacial foi baseada na topologia viária real de cada mapa, com o objetivo de garantir cobertura adequada da área de interesse e permitir a ocorrência de eventos de handover entre as células.

Optou-se por utilizar três estações rádio-base ativas por cenário, uma escolha que equilibra a complexidade da simulação com a necessidade de representar sobreposição de cobertura e zonas de handover. Embora o posicionamento de antenas seja um tema relevante em redes móveis, com abordagens que consideram heurísticas de cobertura, densidade populacional, propagação de sinal e minimização de interferência, este trabalho não aprofunda tais técnicas. O foco permanece na avaliação do mecanismo preditivo de handover, assumindo um posicionamento fixo e conhecido das gNodeBs como premissa simplificadora.

Essa decisão permite isolar o comportamento do modelo de predição frente a diferentes padrões de mobilidade e qualidade de sinal, sem interferência direta de estratégias de planejamento de rede. Ainda assim, os posicionamentos escolhidos visam garantir zonas de sobreposição entre células, condição essencial para a ocorrência e análise de eventos de handover.

3.3 Coleta e Preparação de Dados

A preparação dos dados para treinamento e avaliação do modelo preditivo foi realizada a partir de registros extraídos diretamente da simulação integrada OMNeT++/SUMO. O processo foi dividido em três etapas principais: extração da mobilidade, extração das métricas de rede e pré-processamento para formação do dataset final.

3.3.1 Logs de Mobilidade

As trajetórias dos veículos foram geradas no SUMO com base em mapas reais e configuradas para serem rastreadas via TraCI. No OMNeT++, a ativação da opção `tracemobility` possibilitou a gravação das posições e velocidades dos veículos em cada timestamp, exportadas como vetores para posterior análise.

3.3.2 Logs de Qualidade de Sinal e Eventos de Handover

O OMNeT++ gerou arquivos `.vec` contendo séries temporais de múltiplos parâmetros configurados na simulação. Dentre as variáveis extraídas destacam-se:

- **Identificador da célula servidora:** Usado para determinar mudanças de célula e detectar eventos de handover.
- **Atrasos na camada MAC:**
 - Uplink: `macDelayUL`
 - Downlink: `macDelayDL`
- **Indicadores de qualidade do canal:**
 - CQI uplink: `averageCqiUL`
 - CQI downlink: `averageCqiDL`
- **Vazão gerada por aplicações VoIP:** Registrada como `voIPGeneratedThroughput`.

Esses dados foram filtrados por tipo “vector” e agrupados por timestamp e veículo, mantendo apenas os registros relevantes.

3.3.3 Pré-processamento e Construção do Dataset

O pré-processamento foi realizado por meio de scripts em Python com pandas. As séries foram processadas com base em expressões regulares que identificavam os parâmetros desejados no campo `name` e o número do carro no campo `module`.

Para cada parâmetro, construiu-se um dataframe contendo timestamp, valor do parâmetro e identificação do veículo. Esses dataframes foram então combinados em uma única estrutura final, com regras específicas de preenchimento para valores ausentes: preenchimento com zero para métricas como atraso e throughput, e forward-fill para indicadores como CQI.

Uma etapa fundamental no processamento consistiu na definição da variável-alvo `handover`. Para isso, foi criada uma nova coluna binária indicando se houve troca de célula entre dois timestamps consecutivos para o mesmo

veículo. A comparação entre os valores das colunas `serving_cell` e `next_serving_cell` permite detectar mudanças de associação e, portanto, marca a ocorrência de um handover no instante corrente. Essa abordagem é simples, mas eficaz para inferir o evento com base nos dados extraídos diretamente do simulador. Um exemplo dos dados finais pode ser visto na Tabela 2

timestamp	car	serving_cell	mac_delay_ul	mac_delay_dl	average_cqi_dl	throughput	handover	pos_x	pos_y
1.500	0	0.0	0.000	0.000	0.0	26.67	0	1840.46	8646.03
1.505	0	0.0	0.000	0.000	14.0	0.00	0	1840.46	8646.03
1.509	0	0.0	0.004	0.004	14.0	0.00	0	1840.46	8646.03
1.520	0	0.0	0.000	0.000	14.0	52.63	0	1840.46	8646.03
1.524	0	0.0	0.000	0.000	14.0	0.00	0	1840.46	8646.03

Table 2. Exemplo de registros do dataset após o pré-processamento.

3.4 Modelagem de Aprendizado de Máquina

Nesta etapa, foi implementado um modelo de aprendizado de máquina supervisionado baseado em redes neurais recorrentes, com foco específico na arquitetura Long Short-Term Memory (LSTM). O objetivo principal da modelagem foi aprender padrões temporais nos dados veiculares capazes de antecipar eventos de handover em redes móveis 5G/6G.

3.4.1 Estrutura do modelo LSTM

A rede LSTM foi escolhida devido à sua capacidade de capturar dependências temporais de longo prazo, característica essencial para a tarefa, uma vez que a ocorrência de um handover está diretamente ligada à trajetória e ao comportamento passado do veículo. A estrutura adotada consiste em uma camada LSTM com unidades recorrentes, seguida por camadas densas que realizam a classificação binária (com ou sem handover). A função de ativação da camada de saída é a sigmoid, apropriada para problemas de classificação binária. Para otimização, utilizou-se o otimizador Adam com taxa de aprendizado ajustável, e como função de perda, a binary cross-entropy, ponderada por pesos inversamente proporcionais à frequência das classes.

Os dados foram organizados em janelas deslizantes de tamanho fixo, com 10 instantes consecutivos por amostra, o que permitiu ao modelo aprender transições ao longo do tempo. Na Figura 8 podemos ver a representação detalhada da célula LSTM, evidenciando como os vetores de entrada e saída interagem com os estados internos por meio de operações como somas, multiplicações e ativações não lineares. As portas de entrada, esquecimento e saída controlam o fluxo de memória e aprendizado ao longo do tempo.

3.4.2 Divisão dos dados

Após a construção das janelas, foi aplicado um processo de balanceamento para mitigar a alta desproporção entre as classes. Cada janela com evento de handover foi mantida, enquanto o número de janelas sem handover foi reduzido a, no máximo, cinco vezes esse total, preservando a diversidade dos dados negativos. Os dados foram então divididos em três subconjuntos: treino (70%), validação (15%)

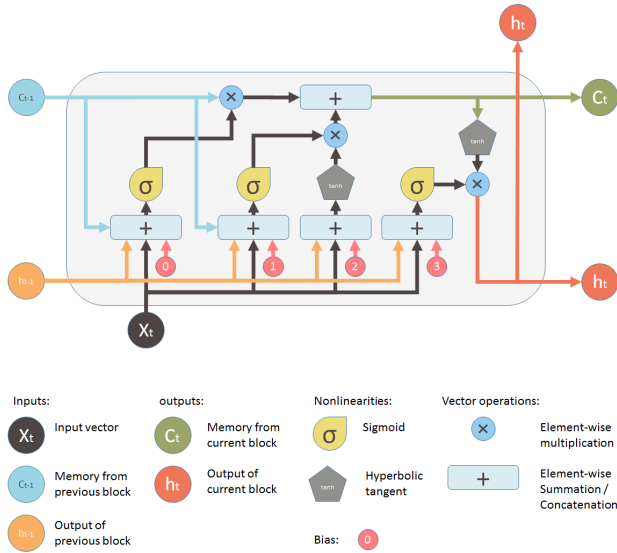


Figure 8. Estrutura interna de uma célula LSTM

e teste (15%), com estratificação por classe. Esse procedimento garantiu avaliação justa do modelo em dados não vistos e preservou a distribuição dos handovers em todos os conjuntos.

3.4.3 Ferramentas utilizadas

A implementação foi realizada com a biblioteca TensorFlow e sua API de alto nível Keras, amplamente adotada para construção de modelos neurais. Também foram utilizadas as bibliotecas NumPy e Pandas para manipulação de dados, além de scikit-learn para procedimentos auxiliares como normalização, divisão dos dados e cálculo de métricas. O treinamento foi conduzido em ambiente com suporte a GPU, utilizando Google Colab, a fim de garantir viabilidade computacional no ajuste de parâmetros do modelo.

4. RESULTADOS

4.1 Avaliação de Performance de ML

Para avaliar a eficácia do modelo LSTM na predição de eventos de handover, foram utilizadas métricas clássicas de classificação binária, tais como acurácia, precision, recall e F1-score, além da análise por curva ROC e PR (Precision-Recall).

A matriz de confusão (Figura 9) indica que o modelo obteve excelente desempenho geral, com 173 verdadeiros positivos e apenas 8 falsos negativos entre os 181 handovers reais no conjunto de teste. Em contrapartida, houve 76 falsos positivos, refletindo uma leve superestimação na detecção de eventos. Ainda assim, a taxa de acerto permanece alta, especialmente considerando o forte desbalanceamento da base original.

As métricas agregadas reforçam essa conclusão, como pode ser visto na Tabela 3), onde a classe 0 indica "sem handover" e a classe 1 "com handover".

Estes valores demonstram que o modelo é especialmente eficaz em capturar eventos reais de handover (alto




Figure 9. Matriz de Confusão de Handovers

Classe	Precisão	Revocação	F1-score	Suporte
0	0,9938	0,8796	0,9332	905
1	0,6175	0,9724	0,7554	181

Table 3. Tabela de classificação por classe

recall), mesmo ao custo de um aumento moderado de falsos positivos.

As curvas ROC (Figura 10) e PR (Figura 11) mostram um comportamento robusto da rede. A curva ROC atinge uma área sob a curva (AUC-ROC) de 0.9856, evidenciando forte capacidade discriminativa. Já a curva Precision-Recall mantém valores elevados de precisão ao longo de praticamente todo o intervalo de recall, indicando estabilidade no desempenho mesmo diante de variações no threshold de decisão.

Além da análise global, foram examinadas as métricas por cenário de mobilidade: Bairro estudantil (A), rodovia (B) e centro urbano (C). O desempenho variou de acordo com o tipo de ambiente (Figura 12). O modelo obteve sua




Figure 10. Curva ROC

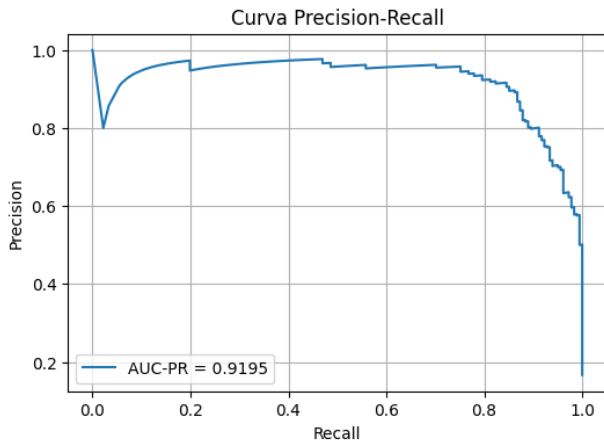


Figure 11. Curva PR




Figure 12. Desempenho do Modelo por Cenário (Classe Handover)

melhor performance no cenário A, com F1-score de 82%, seguido do cenário C (76%) e B (61%). Esse comportamento pode ser explicado por diferenças na velocidade dos veículos, densidade de tráfego e topologia da rede, o que foi aprofundado na análise de erros.

A análise de erros por cenário (Figura 13) evidenciou que os falsos positivos se concentram especialmente nos cenários A e B, sugerindo que em contextos com maior movimentação ou trocas rápidas de sinal, o modelo tende a sinalizar um handover que não ocorre. Em contrapartida, falsos negativos são poucos e distribuídos de forma mais homogênea.

Por fim, a análise das características dos erros (Figuras 14 e 15) revelou que falsos positivos costumam ocorrer em situações de alta velocidade e baixa qualidade de canal (CQI), enquanto os falsos negativos tendem a surgir em velocidades mais baixas. Essa diferenciação reforça a importância da inclusão de variáveis contextuais no processo de tomada de decisão.

4.2 Avaliação de Performance de Rede

Além das métricas tradicionais de aprendizado de máquina, é essencial avaliar o impacto prático do mod-

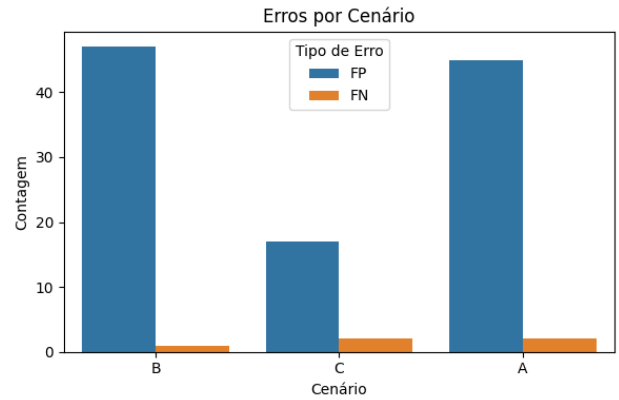


Figure 13. Erros por Cenário




Figure 14. Velocidade nas Situações de Erro

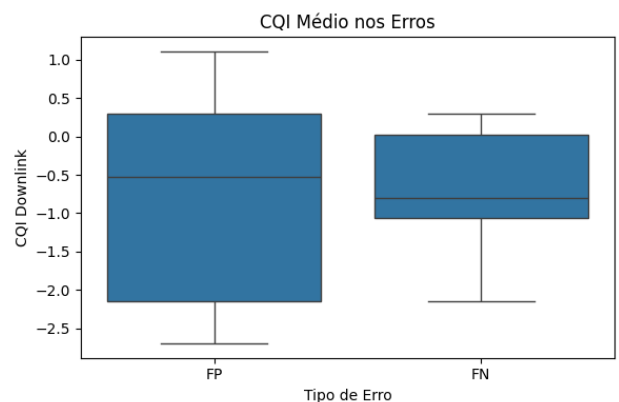


Figure 15. CQI Médio nos Erros




Figure 16. MAC Delay Upper Link: Comparação antes e depois do handover preditivo




Figure 17. MAC Delay Down Link: Comparação antes e depois do handover preditivo

elo de predição sobre o desempenho da rede. Para isso, comparamos indicadores-chave da comunicação veicular associados a eventos de handover: handover rate, ping-pong rate, latência média, throughput e qualidade do canal (CQI). A análise foi realizada a partir de uma simulação offline, comparando os efeitos dos handovers reais e dos handovers previstos pelo modelo.

O handover rate da política tradicional, extraído dos dados simulados, foi de 125 eventos, enquanto a política baseada no modelo preditivo gerou 285 eventos, o que representa um aumento significativo na frequência de troca de antena. Apesar disso, quando considerada uma tolerância temporal de ± 5 passos de tempo, o modelo acertou 65 eventos, indicando boa sensibilidade às condições que precedem um handover.

Quanto à latência média (MAC delay), observou-se um leve aumento após o handover em ambos os casos (Figura 16 e Figura 17). No entanto, a diferença entre os valores antes e depois do evento foi pequena, sugerindo que o impacto da troca de estação é controlado tanto na abordagem real quanto na preditiva.

No que se refere ao throughput, os resultados apontam comportamentos distintos: enquanto os handovers reais apresentaram redução média de 82 kbps após o evento, os handovers previstos pelo modelo levaram a um aumento médio de 14 kbps no throughput pós-handover (Figura

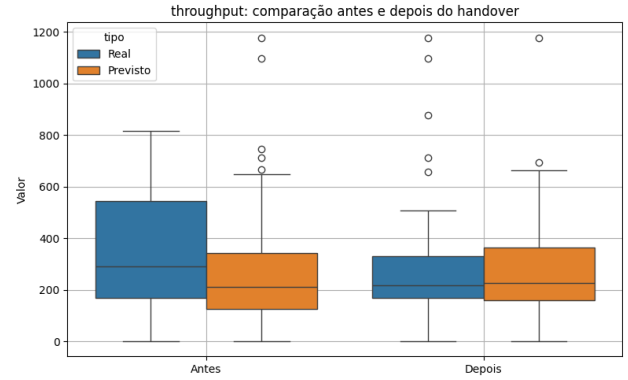


Figure 18. Throughput: Comparação antes e depois do handover preditivo




Figure 19. CQI: Comparação antes e depois do handover preditivo

18). Esse comportamento sugere que o modelo, ao antecipar a troca de estação, consegue evitar quedas bruscas de desempenho que normalmente motivariam um handover pela política tradicional.

Por fim, a análise da métrica CQI (Channel Quality Indicator) downstream (Figura 19) revelou que tanto nos handovers reais quanto nos previstos há uma pequena elevação da qualidade do canal após o evento, reforçando o papel do handover como mecanismo de manutenção da qualidade de comunicação. A melhoria média foi de aproximadamente 0.2 pontos de CQI para handovers reais e 0.1 pontos para os previstos.

Esses resultados indicam que, embora o modelo preditivo gere mais eventos, ele tende a manter ou até melhorar a qualidade dos indicadores de rede, especialmente em termos de throughput, justificando seu uso como alternativa à política reativa tradicional. As demais comparações e métricas podem ser vistas na Tabela 4.

4.3 Análise Crítica

Apesar dos resultados promissores obtidos com a abordagem de predição de handovers via aprendizado de máquina, é fundamental reconhecer as limitações do estudo e discutir possibilidades de aprimoramento.

A primeira limitação refere-se a base original, que apresentava um extremo desbalanceamento (apenas 170 han-

Tipo	Métrica	Antes	Depois	Diferença
Real	mac_delay_ul	0,001139	0,001238	0,000099
Real	mac_delay_dl	0,001139	0,001238	0,000099
Real	throughput	341,909	259,745	-82,164
Real	average_cqi_dl	9,731	9,936	0,205
Previsto	mac_delay_ul	0,001158	0,001320	0,000162
Previsto	mac_delay_dl	0,001158	0,001320	0,000162
Previsto	throughput	236,103	250,829	14,726
Previsto	average_cqi_dl	9,308	9,408	0,100

Table 4. Médias das métricas antes e depois do handover (real e previsto)

dovers em mais de 887 mil amostras), o que exigiu técnicas agressivas de undersampling e filtragem de janelas para viabilizar o treinamento supervisionado. Embora eficaz, esse processo reduz a diversidade de padrões negativos, o que pode prejudicar a robustez do modelo frente a situações não observadas.

Outro ponto crítico é o custo de decisões incorretas. Embora o modelo tenha alcançado ótimos resultados em termos de F1-score e recall para a classe minoritária, a introdução de falsos positivos ainda é uma preocupação. Esses eventos geram handovers desnecessários, impactando potencialmente o consumo de sinalização, o uso de recursos da rede de acesso e, em cenários reais, até a experiência do usuário. A ausência de uma política de supressão de handovers sucessivos (efeito ping-pong) também pode amplificar esse problema.

Por fim, a avaliação de impacto em métricas de rede foi realizada de forma offline e indireta, por meio de comparações antes e depois de eventos previstos. Embora útil, essa abordagem não substitui uma avaliação em tempo real, onde as decisões do modelo afetam diretamente a mobilidade e o tráfego da rede. A integração do modelo ao ambiente de simulação em execução, ou até mesmo a testes reais em testbeds, seria o próximo passo ideal para validar sua viabilidade prática.

5. TRABALHOS RELACIONADOS

Este trabalho se insere em um cenário de crescente interesse por mecanismos de handover preditivo que utilizam aprendizado de máquina para mitigar os efeitos da mobilidade em redes 5G e futuras 6G. Três abordagens da literatura recente se destacam por apresentarem propostas com alto grau de afinidade à arquitetura, metodologia e objetivos deste estudo.

Topazal et al. (2025) [2] oferece uma visão abrangente sobre o uso de LSTM para otimizar handovers em redes 5G/6G, com ênfase em aplicações D2D e IoT. Sua proposta destaca a importância de decisões inteligentes baseadas em aprendizado profundo, servindo como base conceitual importante para o presente estudo. No entanto, o enfoque permanece teórico, sem avaliação experimental em cenários realistas.

Panitsas et al. (2024) [3] apresentam uma solução elegante e tecnologicamente madura para predição de handover em redes 6G/O-RAN, utilizando LSTM e transfer learning dentro de um xApp, atingindo impressionantes

92% de acurácia na previsão de célula alvo, além de reduzir drasticamente (91%) o tempo de retreinamento após mudanças dinâmicas da rede. Esse trabalho fornece uma base conceitual valiosa para arquiteturas inteligentes de mobilidade, mostrando como o transfer learning pode viabilizar adaptações rápidas em cenários de alta densidade e com UAVs. No entanto, sua investigação permanece no estágio de simulação celular sintética, sem avaliação com mobilidade veicular realista ou impacto prático nas métricas de rede.

Ali et al. (2025) [4] apresentam o mecanismo in-time conditional handover (iCHO) para redes B5G/6G, que utiliza dados históricos de mobilidade para estimar o tempo de permanência do usuário na célula atual, reduzindo overhead de reservas de recursos e melhorando a precisão da decisão de troca. A solução demonstra desempenho notável, com precisão de previsão superiores a 98%, o que representa um avanço significativo na inteligência de handovers baseados em durações temporais. O estudo serve como forte referência teórica e metodológica ao apresentar uma maneira eficaz de antecipar o momento da troca de célula.

A principal contribuição deste trabalho, frente aos estudos analisados, está na integração entre mobilidade veicular realista, modelo LSTM supervisionado e avaliação conjunta das métricas de rede e de classificação. Ao utilizar três cenários distintos (urbano denso, bairro residencial e rodovia), o estudo demonstra a robustez da abordagem proposta em condições heterogêneas de tráfego e topologia. Além disso, os experimentos revelam que, mesmo com um aumento na frequência de handovers, o modelo preditivo pode melhorar o throughput e manter a qualidade da comunicação, validando sua aplicabilidade prática.

6. CONCLUSÃO

Este trabalho apresentou um mecanismo de handover preditivo para redes veiculares 5G, baseado em redes LSTM treinadas com dados realistas de mobilidade e qualidade de sinal. A proposta foi avaliada em três cenários distintos (bairro residencial, rodovia e centro urbano denso) por meio de simulações integradas nos ambientes SUMO, OMNeT++, Veins, INET e Simu5G. O modelo demonstrou excelente capacidade de antecipar eventos de handover, com alto recall mesmo em um contexto fortemente desbalanceado, e desempenho robusto em múltiplas topologias.

Os resultados indicaram que a predição proativa contribui para a manutenção da qualidade de serviço em cenários de alta mobilidade, promovendo aumentos de throughput e evitando quedas bruscas no desempenho da rede. Apesar do aumento no número total de handovers previstos, o impacto negativo foi contido, e os benefícios em termos de continuidade e estabilidade da conexão se mostraram significativos.

Como limitações, destacam-se a natureza offline da avaliação e a simplificação do posicionamento das antenas. Além disso, o tratamento do desbalanceamento extremo exigiu filtragem agressiva da base negativa, o que

pode limitar a generalização do modelo. Como trabalhos futuros, propõe-se a integração do modelo ao ambiente de simulação em tempo real, bem como a adoção de técnicas mais avançadas de balanceamento e regularização, como focal loss, oversampling inteligente ou aprendizado semi-supervisionado. Também se vislumbra a extensão da arquitetura para múltiplas classes (ex.: tipo de handover) ou previsão contínua baseada em regressão, ampliando a aplicabilidade da abordagem para redes 6G e além.

7. APÊNDICE

As simulações, implementações, tabelas e gráficos deste trabalho estão disponíveis no repositório GitHub: <https://github.com/estersassis/predictive-handover-5g-vnet>.

8. REFERENCES

- [1] Saeed, R. A. (2019). Handover in a mobile wireless communication network – A Review Phase. The International Journal of Computer, Communication and Information, 6–13. Disponível em: <https://isi-web.org/sites/default/files/2024-02/Handling-Data-Imbalance-in-Machine-Learning.pdf>.
- [2] TOPAZAL, S M; et al. Intelligent device to device handover management techniques for 5G/6G and beyond, 2025. Disponível em: <https://link.springer.com/article/10.1007/s11227-025-07182-1>.
- [3] PANITSAS, Ioannis; et al. Predictive Handover Strategy in 6G and Beyond: A Deep and Transfer Learning Approach, 2024. Disponível em: <https://arxiv.org/abs/2404.08113>.
- [4] ALI, Sardar; et al. In-time conditional handover for B5G/6G, 2025. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0140366425000647>.
- [5] TAN, Kang; et al. Machine learning in vehicular networking: An overview, 2022. Disponível em: <https://www.sciencedirect.com/science/article/pii/S2352864821000870>.
- [6] AWE, O. Olawale. Computational Strategies for Handling Imbalanced Data in Machine Learning. Disponível em: <https://isi-web.org/sites/default/files/2024-02/Handling-Data-Imbalance-in-Machine-Learning.pdf>.
- [7] IPLOOK. Basic Handover Types in Mobile Network. Disponível em: <https://www.iplook.com/info/basic-handover-types-in-mobile-network-i00362i1.html>.
- [8] PROJECTPRO. LSTM Model: Learn How to Build an LSTM Model in Python. Disponível em: <https://www.projectpro.io/article/lstm-model/832>.
- [9] Kurose, Jim. Writing a good introduction, 2004. Disponível em: <https://www.cs.columbia.edu/~hgs/etc/intro-style.html>.